

1. baseline方法

1.1 GRACE (node-level graph contrastive learning 方法)

给定图：

$$G = (X, A),$$

其中 X 是节点特征， A 是邻接矩阵。

GRACE 先对原图做两次随机增强：

$$G^{(1)} = (X^{(1)}, A^{(1)}),$$

$$G^{(2)} = (X^{(2)}, A^{(2)}).$$

增强包括：

- edge dropping;
- feature masking.

$$Z^{(1)} = g_\phi(f_\theta(G^{(1)})),$$

$$Z^{(2)} = g_\phi(f_\theta(G^{(2)})).$$

这上面， f 是GNN， g 是projector。对节点 i ，正样本是同一个节点在两个增强视图中的表示：

$$(z_i^{(1)}, z_i^{(2)}).$$

负样本是其他节点：

$$(z_i^{(1)}, z_j^{(2)}), \quad j \neq i.$$

loss 为：

$$\ell_i^{1 \rightarrow 2} = -\log \frac{\exp(s(z_i^{(1)}, z_i^{(2)})/\tau)}{\exp(s(z_i^{(1)}, z_i^{(2)})/\tau) + \sum_{j \neq i} \exp(s(z_i^{(1)}, z_j^{(2)})/\tau)}.$$

通常还会加入反向：

$$\mathcal{L}_{\text{GRACE}} = \frac{1}{2N} \sum_i (\ell_i^{1 \rightarrow 2} + \ell_i^{2 \rightarrow 1}).$$

1.2 DGI (node-level local-global contrastive learning)

给定图：

$$G = (X, A).$$

先编码原图：

$$H = f_\theta(X, A),$$

其中：

$$H = [h_1, h_2, \dots, h_N].$$

然后用 READOUT 得到图级 summary：

$$s_G = \sigma(\text{READOUT}(H)).$$

常见 READOUT 是平均池化：

$$\text{READOUT}(H) = \frac{1}{N} \sum_{i=1}^N h_i.$$

DGI 构造 corrupted graph。（构造方法是打乱特征矩阵的行）：

$$\tilde{X} = \text{Shuffle}(X).$$

也就是说：

$$\tilde{x}_i = x_{\pi(i)},$$

其中 $\pi(i)$ 是一个随机排列。

注意，DGI 通常保持图结构不变：

$$\tilde{G} = (\tilde{X}, A).$$

然后编码 corrupted graph：

$$\tilde{H} = f_{\theta}(\tilde{X}, A).$$

DGI 的正样本是：

$$(h_i, s_G).$$

DGI 的负样本是：

$$(\tilde{h}_i, s_G).$$

判别器通常是 bilinear scoring：

$$D(h_i, s_G) = \sigma(h_i^{\top} W s_G).$$

原始 DGI loss 是 binary cross entropy：

$$\mathcal{L}_{\text{DGI}} = - \sum_i \left[\log D(h_i, s_G) + \log(1 - D(\tilde{h}_i, s_G)) \right].$$

但 DGI 的 corruption 通常只是 feature shuffle，结构 A 不变。因此：

$$\tilde{h}_i = f_{\theta}(\tilde{X}, A)_i$$

仍然会受到原图结构 message passing 的影响。

如果 $\tilde{x}_i = x_{\pi(i)}$ 中的源节点 $\pi(i)$ 与目标位置 i 结构相似、语义相似、甚至同类，那么 $(\tilde{h}_i, s_G)$ 不一定是真正的 negative。

1.3 GraphCL graph-level contrastive learning 方法。

给定一个 batch 的图：

$$\{G_1, G_2, \dots, G_B\}.$$

对每个图 G_k 做两次图增强：

$$G_k^{(1)}, \quad G_k^{(2)}.$$

常见增强包括：

- node dropping;
- edge perturbation;
- attribute masking;
- subgraph sampling.

编码得到 graph-level embedding：

$$z_k^{(1)} = f_\theta(G_k^{(1)}),$$

$$z_k^{(2)} = f_\theta(G_k^{(2)}).$$

对图 G_k ，正样本是：

$$(z_k^{(1)}, z_k^{(2)}).$$

负样本是 batch 中其他图：

$$(z_k^{(1)}, z_l^{(2)}), \quad l \neq k.$$

原始 GraphCL loss 是：

$$\ell_k^{1 \rightarrow 2} = -\log \frac{\exp(s(z_k^{(1)}, z_k^{(2)})/\tau)}{\exp(s(z_k^{(1)}, z_k^{(2)})/\tau) + \sum_{l \neq k} \exp(s(z_k^{(1)}, z_l^{(2)})/\tau)}.$$

1.4 总结

方法	对比类型	原始 positive	原始 negative	问题
GRACE	node-node	同一节点的两个增强视图	其他节点	positive augmentation 可能破坏局部语义；negative 中可能有同类节点或结构相似节点
DGI	node-summary	原图节点与全图 summary	corrupted 节点与原图 summary	feature shuffle 不一定真的破坏语义；corrupted negative 可能仍然合理
GraphCL	graph-graph	同一图的两个增强视图	batch 中其他图	graph augmentation 可能破坏图级语义；其他图可能是同类或结构相似图

2 方法介绍

思想上和之前还是一样的，不同 positive pair 的可靠性并不相同，不同 negative pair 也不应被同等地视为负样本。

我们在对比学习目标中加入正样本可靠性和真负样本概率，用于控制正样本和负样本。

对于一个训练实例 o ，我们令 $z_o^{(1)}$ 和 $z_o^{(2)}$ 分别表示其在两个增强视图中的表示。

我们首先定义正样本可靠性：

$$\rho_o^+ = \text{sim}(\psi_o^{(1)}, \psi_o^{(2)}),$$

其中， $\psi_o^{(1)}$ 和 $\psi_o^{(2)}$ 分别表示实例 o 在两个视图中的结构与上下文描述符。较大的 ρ_o^+ 表明增强后两个视图仍然保持相似的局部结构上下文，因此该 positive pair 更可靠；较小的 ρ_o^+ 则表明增强可能破坏了结构语义，该 positive pair 的训练信号应被削弱。

对于负样本，我们估计候选样本 j 是实例 o 的真负样本的概率：

$$p_{oj}^{\text{TN}} = \sigma(1 - s(z_i, z_j) - \text{sim}(\psi_i^0, \psi_j^0)).$$

该概率综合考虑表示相似度、结构相似度、图上邻近性等因素。若 j 与 o 在结构或语义上高度相似，则 p_{oj}^{TN} 较小，说明该样本可能并不适合作为强负样本；反之，若二者差异较大，则 p_{oj}^{TN} 较大。

它通过 p_{oj}^{TN} 降低疑似假负样本在 denominator 中的贡献，从而避免将结构或语义上相近的样本错误地强行推远。

最终，可靠性修正后的对比学习目标为：

$$\ell_o = -\log \frac{\exp(\rho_o^+ s(z_o^{(1)}, z_o^{(2)})/\tau)}{\exp(\rho_o^+ s(z_o^{(1)}, z_o^{(2)})/\tau) + \sum_{j \neq o} p_{oj}^{\text{TN}} \exp(s(z_o^{(1)}, z_j^{(2)})/\tau)}.$$

可靠的 positive pair 会被更强地拉近，而疑似 false negative 的样本将不会被强行推远。

3.1 Node-level 结构标志符的统一定义

对节点 i ，定义：

$$\psi_i = [\psi_i^{\text{str}} \parallel \psi_i^{\text{ctx}}].$$

其中：

结构描述符

$$\psi_i^{\text{str}} = [\log(d_i + 1), c_i, \text{EgoDensity}_k(i), \text{PE}_i].$$

含义：

- d_i ：节点度数；
- c_i ：clustering coefficient；
- $\text{EgoDensity}_k(i)$ ： k -hop ego graph density；
- PE_i ：Laplacian PE。

上下文语义描述符

$$\psi_i^{\text{ctx}} = \frac{1}{|\mathcal{N}_k(i)|} \sum_{u \in \mathcal{N}_k(i)} x_u.$$

2.2 GRACE 中的 ψ_i

GRACE 有两个增强图:

$$G^{(1)}, \quad G^{(2)}.$$

因此分别计算:

$$\psi_i^{(1)} = \psi_i(G^{(1)}),$$

$$\psi_i^{(2)} = \psi_i(G^{(2)}).$$

positive reliability 定义为:

$$\rho_i^+ = \frac{1 + \cos(\psi_i^{(1)}, \psi_i^{(2)})}{2}.$$

negative reliability :

$$p_{ij}^{\text{TN}} = \sigma(1 - s(z_i, z_j) - \text{sim}(\psi_i^0, \psi_j^0)).$$

或者是

$$p_{ij}^{\text{TN}} = \sigma(1 - \text{sim}(\psi_i^0, \psi_j^0)).$$

$$\ell_i = \rho_i^+ \left[-\log \frac{\exp(s(z_i^{(1)}, z_i^{(2)})/\tau)}{\exp(s(z_i^{(1)}, z_i^{(2)})/\tau) + \sum_{j \neq i} p_{ij}^{\text{TN}} \exp(s(z_i^{(1)}, z_j^{(2)})/\tau)} \right].$$

2.3 DGI 中的 ψ_i

DGI 的 corruption 是:

$$\tilde{x}_i = x_{\pi(i)}.$$

因此, DGI 中不应该简单比较 ψ_i 和 $\tilde{\psi}_i$, 因为如果 ψ_i 只包含拓扑, corruption 前后它们可能完全一样。

DGI 应该比较:

- 目标位置 i 的局部上下文;
- 源节点 $\pi(i)$ 的内容和结构角色。

目标位置描述符:

定义 compatibility:

$$\text{Compat}(i, \pi(i)) = \text{sim}(\psi_{\pi(i)}, \psi_i)$$

然后:

$$p_i^{\text{TC}} = \sigma(1 - \text{Compat}(i, \pi(i))).$$

如果 compatibility 高, 则 corrupted negative 不一定真的 corrupted:

$$p_i^{\text{TC}} \downarrow.$$

如果 compatibility 低, 则 corrupted negative 更可能 truly corrupted:

$$p_i^{\text{TC}} \uparrow.$$

$$\mathcal{L} = - \sum_i \left[\log D(h_i, s_G) + p_i^{\text{TC}} \log(1 - D(\tilde{h}_i, s_G)) \right].$$